

Tabela główna							
Model	Typ uczenia	Accuracy	Balanced Accuracy	Precision Anomaly	Recall Anomaly	F1 Anomaly	ROC AUC
Random Forest	supervised	0.8643	0.8786	0.7684	0.9583	0.8529	0.9617
Isolation Forest	anomaly detection	0.6999	0.7178	0.5984	0.8177	0.6911	0.7841
One-Class SVM	one-class / semi-supervised	0.7120	0.7047	0.6450	0.6637	0.6542	0.6483

Tabela przedstawia końcowe wyniki najlepszych konfiguracji trzech analizowanych modeli. Dla Random Forest zastosowano model nadzorowany uczony na próbkach normalnych i anomalnych. Isolation Forest oraz One-Class SVM potraktowano jako modele detekcji anomalii, trenowane wyłącznie na próbkach normalnych. Jako główny zestaw cech przyjęto wariant BASIC, obejmujący cechy długościowe oraz liczbę znaków specjalnych w żądaniach HTTP.

Tabela porównująca zestawy cech: BASIC vs ADVANCED							
Model	Zestaw cech	Accuracy	Balanced Accuracy	Precision Anomaly	Recall Anomaly	F1 Anomaly	ROC AUC
Isolation Forest	ADVANCED	0.6915	0.7082	0.5917	0.8015	0.6808	0.7828
Isolation Forest	BASIC	0.6999	0.7178	0.5984	0.8177	0.6911	0.7841
Random Forest	ADVANCED	0.8584	0.8742	0.7581	0.9621	0.8480	0.9612
Random Forest	BASIC	0.8643	0.8786	0.7684	0.9583	0.8529	0.9617
One-Class SVM	ADVANCED	0.7127	0.7055	0.6456	0.6653	0.6553	0.6501
One-Class SVM	BASIC	0.7120	0.7047	0.6450	0.6637	0.6542	0.6483

Tabela porównuje wyniki modeli dla dwóch zestawów cech wejściowych. Wariant BASIC obejmuje wyłącznie podstawowe cechy strukturalne żądań HTTP, takie jak długość URL, długość treści żądania oraz liczba znaków specjalnych. Wariant ADVANCED rozszerza zestaw BASIC o dodatkowe flagi bezpieczeństwa wykrywane za pomocą wyrażeń regularnych, takie jak `sqli_flag`, `xss_flag` oraz `traversal_flag`. Celem tego porównania było sprawdzenie, czy modele osiągają dobre wyniki dzięki ogólnym cechom strukturalnym, czy głównie dzięki ręcznie zdefiniowanym sygnaturom ataków.

Zestaw cech	Zawartość
BASIC	<code>url_len</code> , <code>content_len</code> , <code>url_special_chars</code> , <code>content_special_chars</code>
ADVANCED	Wszystkie cechy z BASIC + <code>sqli_flag</code> , <code>xss_flag</code> , <code>traversal_flag</code>

Tabela strojenia One-Class SVM						
nu	Accuracy	Balanced Accuracy	Precision Anomaly	Recall Anomaly	F1 Anomaly	ROC AUC
0.1	0.6901	0.6453	0.7244	0.3954	0.5115	0.6028
0.2	0.7082	0.6876	0.6688	0.5727	0.6170	0.6262
0.3	0.7127	0.7055	0.6456	0.6653	0.6553	0.6501
0.4	0.6542	0.6692	0.5584	0.7528	0.6412	0.6905

Tabela przedstawia wpływ parametru `nu` na skuteczność modelu One-Class SVM. Parametr `nu` kontroluje agresywność modelu w oznaczaniu próbek jako anomalne.

Tabela strojenia Isolation Forest						
contamination	Accuracy	Balanced Accuracy	Precision Anomaly	Recall Anomaly	F1 Anomaly	ROC AUC
0.1	0.6559	0.6022	0.6826	0.3024	0.4191	0.7841
0.2	0.7031	0.6794	0.6693	0.5470	0.6020	0.7841
0.3	0.7079	0.7035	0.6350	0.6784	0.6560	0.7841
0.4	0.6999	0.7178	0.5984	0.8177	0.6911	0.7841

Tabela przedstawia wpływ parametru `contamination` na skuteczność modelu Isolation Forest. Parametr ten określa oczekiwany udział anomalii i wpływa na próg decyzyjny modelu, czyli na to, jak często próbki są

klasyfikowane jako anomalne.

Tabele porównawcze							
Random Forest							
Źródło	Dataset	Model	Accuracy / Detection Rate	Precision	Recall	F1-score / F-measure	Uwagi
Moje wyniki	CSIC 2010, CSV/Kaggle	Random Forest	0.8643	0.7684	0.9583	0.8529	cechy BASIC, split 80/20
Althubiti et al.	CSIC 2010 HTTP	Random Forest	0.9994	0.9990	0.9990	0.9990	5 cech, split 60/40
Pham et al. cyt. za Althubiti	CSIC 2010 HTTP	Random Forest	-	0.7970	0.8711	0.8324	
Nguyen et al. cyt. za Althubiti	CSIC 2010 HTTP	Random Forest, Full-Set	0.9371	-	-	-	

Źródło: Analyzing HTTP requests for web intrusion detection - Sara Althubiti, Xiaohong Yuan, Albert Esterline, 2017

Wynik Random Forest uzyskany w projekcie jest zbliżony do wyników Pham et al. przytoczonych przez Althubiti et al., szczególnie pod względem F1-score dla klasy anomalous. Wyniki Althubiti et al. są znacznie wyższe, jednak zostały uzyskane przy innym zestawie cech, innym podziale danych oraz w środowisku Weka.

Isolation Forest							
Źródło	Model	Reprezentacja	Accuracy	Precision	Recall / DR	F1-score	Uwagi
Moje wyniki	Isolation Forest	BASIC	0.6999	0.5984	0.8177	0.6911	proste cechy strukturalne
Vartouni et al.	Isolation Forest	unigram	0.7482	0.7141	0.4685	0.5658	bez autoencodera
Vartouni et al.	Isolation Forest	bigram	0.7190	0.6758	0.3794	0.4860	bez autoencodera
Vartouni et al.	Isolation Forest	bigram + SAE	0.8832	0.8029	0.8834	0.8412	głęboka ekstrakcja cech
Vartouni et al., Leveraging	Isolation Forest	1-gram	0.7723	0.7377	0.5427	0.6254	szybki IF, niższy recall

Isolation Forest na cechach BASIC osiąga wyższy F1-score niż warianty n-gram + IF bez autoenkodera raportowane przez Vartouni et al., ale niższy niż wariant bigram + SAE + IF, co wskazuje na korzyść wynikającą z głębszej ekstrakcji cech.

One-Class SVM							
Źródło	Model	Reprezentacja	Accuracy	Precision	Recall / DR	F1-score	Uwagi
Moje wyniki	One-Class SVM	BASIC	0.7120	0.6450	0.6637	0.6542	StandardScaler, nu = 0.3
Vartouni et al., Leveraging	One-Class SVM	1-gram	0.7968	0.6788	0.7969	0.7331	prosty n-gram
Vartouni et al., Leveraging	One-Class SVM	2-gram	0.8270	0.7000	0.8853	0.7818	prosty n-gram, większa reprezentacja

Źródło: Leveraging Deep Neural Networks for Anomaly-Based Web Application Firewall - Ali Moradi Vartouni, Mohammad Teshnehlab, Saeed Sedighian Kashi

An Anomaly Detection Method to Detect Web Attacks Using Stacked Auto-Encoder - Ali Moradi Vartouni, Mohammad Teshnehlab, Saeed Sedighian Kashi

One-Class SVM w projekcie osiąga niższe wyniki niż warianty n-gramowe z pracy Vartouni et al., ale porównanie wskazuje, że bardziej szczegółowa reprezentacja HTTP requestów, np. 1-gram lub 2-gram, może poprawiać skuteczność metod one-class.

Macierze pomyłek i wykres krzywej ROC, dane z tabeli głównej

